

OpenPI π 0.5 权重

LIBERO 本体对比评测

官方 pi05_libero 微调权重 vs pi05_base 基准权重

97.10%

vs 0.00%

同一套 4 suites $\times$ 10 tasks $\times$ 50 trials 配对矩阵

先确认可比性：同一考场、同一试卷，仅参数能力不同

任务矩阵

4 suites × 10 tasks ×
50 trials = 2000 episodes

输入与推理

224×224 图像 · seed 7
replan steps = 5

成功判定

同一环境与任务描述
固定 suite 最大步数


Base 对照

pi05_base 参数
+ 官方 LIBERO
stats/assets

为什么这个对照重要？

如果 Base 仍然失败，就不能再把原因简单归结为“缺少 LIBERO 的单位换算表或环境资源”。
两组差异反映的是当前固定协议下，任务微调权重是否真正形成了 LIBERO 操作能力。

总体结果：同一 2000-episode 矩阵上为 97.10% vs 0%



一句话结论


任务微调权重是获得 **LIBERO** 操作能力的决定性因素。

观察差距 97.1 个百分点；任务配对 bootstrap 95% CI 为 94.80–98.65 。

官方权重通过 93.85% 验收线； Base 95% CI 上界仅 0.19% 。

逐 episode 配对: **Base** 没有任何一次反超

逐 episode 配对: 1,942 次官方胜出, Base 反超为 0



配对键: suite × task × trial × seed ; 两边都失败 58 次

一句话结论


1,942 次差异全部指向官方权重成功、**Base** 失败。

官方胜出 1,942 次;
Base 胜出 0 次。

两边共同失败 58 次; 配对一致率 2.9% , 且全部是共同失败。

Suite 分解：差距覆盖空间、物体、目标与长时序任务

四个任务套件全部拉开差距；LIBERO-10 是微调权重的相对短板



一句话结论

四个 **suite** 全部拉开差距，不是单一题型的偶发现象。

微调权重： Spatial
98.6%、 Object 98.4%、
Goal 98.2%、 LIBERO-10
93.2%。

Base 四套均为
0/500。

40 个任务热力图：微调权重多数接近满分，Base 全部为 0


40 个任务 × 50 trials：微调权重多数任务接近满分，Base 在每个任务上均为 0



每个格子包含 50 次 trial；颜色和数字均为任务级成功率。

任务级稳定性： **29/40** 个任务达到至少 **98%**

官方微调权重的任务级稳定性：29/40 个任务 $\geq 98\%$ ，19 个任务满分




一句话结论

高分并非来自少数任务拉高平均：多数任务本身就接近满分。

19 个任务 100%； 29 个任务 $\geq 98\%$ ； 37 个任务 $\geq 94\%$ 。

Base： 40/40 个任务均为 0%。

失败长尾：58 次失败的一半集中在 3 个任务



一句话结论

总体 97.10% 仍掩盖少数长时序任务的明显风险。

最难任务：两只 moka pot 放到炉灶，30/50 = 60%。

Top-3 占 51.7% 失败；
Top-5 占 62.1%。

动作预算： **Base** 不是快速报错，而是持续尝试后全部超时

Base 在每个 suite 都耗尽 100% 动作预算；微调权重平均使用约一半




一句话结论

Base 的 2000 次失败都跑满最大步数，属于系统性策略失败。

官方总动作 318,664 步； Base 660,000 步。

微调权重少执行 341,336 步，减少 51.7%。

评测成本：Base 的 episode-duration 总和达到 1.90 倍



一句话结论


不会做的权重不仅得分低，也会持续消耗动作与评测时间。

官方 5.53h ; Base 10.52h。

中位 episode 时长：
8.58s vs 15.98s。

探索性观察：高动作预算使用与困难任务相伴

探索性观察：更高动作预算使用通常伴随更低任务成功率



一句话结论

最难任务既成功率最低，也最接近耗尽动作预算。

该图用于定位困难任务和长尾，不构成因果结论。

建议后续针对多物体、长时序、状态恢复任务做专门回归。

为什么可以相信这些数字：结果能力与证据质量分开验收

2000 / 2000

每份权重矩阵完整

2000

唯一 episode + attempt

2000

非空录像一一对应

0

基础设施错误

Exact

任务 / 试次配对一致

Passed

最终独立审计

每个分数都能回溯到 JSONL、录像、日志、manifest、Git commit 与 checkpoint 哈希。

结论：微调权重形成了任务能力，但仍需关注长时序尾部风险

本次数据能够证明

1. 官方 pi05_libero 在原始 LIBERO 上达到 97.10%。
2. Base 即使搭配相同 stats/assets 仍为 0%。
3. norm stats 不能替代任务微调能力。
4. 剩余失败集中在少数长时序任务。

本次数据不能直接证明

1. 真实机器人部署安全。
2. 其他任务或其他适配下 Base 必然失败。
3. 跨随机 seed 的性能方差。
4. 所有微调方法都能产生同样增益。

结论：同一试卷 97.10% vs 0%，任务微调权重而非仅数据归一化决定了 LIBERO 能力。